Nombre: Morales Gonzales Emmanuel – Boleta: 2025630602, Romero Sayun Jonathan – Boleta: 2025630298 ° Grupo: 3CV4

Ejercicio 5. Modelo EER del proyecto asignado

Proyecto asignado: Consumo de agua de la Ciudad de México.

Dominio

El sistema consolida dos fuentes abiertas de 2019: las lecturas de consumo de agua que publica SACMEX (71,102 registros en tres fechas de referencia, una por bimestre) y la serie climática de Open-Meteo (4,344 mediciones horarias del 1 de enero al 30 de junio, 181 días). En la realidad existen:

- Un territorio anidado: **alcaldías** (16) que contienen **colonias**, que contienen **manzanas**, que es la unidad a la que se refiere cada registro de consumo.

- **Periodos de facturación** (bimestres) formados por **días**.

- Una **lectura de consumo** por manzana y bimestre, que se desglosa por **tipo de uso** (doméstico, no doméstico, mixto) y se clasifica con un **índice de desarrollo** de cuatro niveles ordinales (ALTO, MEDIO, BAJO, POPULAR).

- Una **estación climática** (19.44° N, 99.11° O, 2,233 m) que produce una **observación diaria** (temperaturas, humedad, lluvia).

- Una relación derivada de **cercanía** entre colonias (centroides a 1.5 km o menos).

Entidades débiles y jerarquías del dominio

Entidades débiles

El dominio tiene cuatro cadenas de dependencia de identificación, todas comprobadas contra el archivo CSV de consumo del repositorio:

1. **COLONIA depende de ALCALDÍA.** 54 nombres de colonia aparecen en más de una alcaldía (por ejemplo, ADOLFO LOPEZ MATEOS, ALVARO OBREGON, BENITO JUAREZ), por lo que el nombre por sí solo no identifica a la colonia. Hay 1,553 pares (alcaldía, colonia) distintos y solo 1,494 nombres distintos. Clave parcial: nombre.

2. **MANZANA depende de COLONIA.** Ninguna de las 22,930 coordenadas distintas del archivo pertenece a más de una colonia, pero la fuente no publica una clave de manzana: la unidad solo se distingue por su ubicación dentro de la colonia. Clave parcial: ubicación (latitud, longitud).
3. **LECTURA DE CONSUMO depende de MANZANA y BIMESTRE.** Una lectura no existe sin la manzana a la que corresponde ni el bimestre que cubre, y se identifica por la pareja. Es una entidad débil con dos propietarias, mediante las relaciones identificadoras TIENE LECTURA y CORRESPONDE A.
4. **CONSUMO POR USO depende de LECTURA DE CONSUMO.** El desglose doméstico, no doméstico y mixto no tiene sentido fuera de su lectura. Se identifica por la lectura y el tipo de uso (clave parcial: tipo_uso), mediante la relación identificadora SE DESGLOSA EN.

Además, OBSERVACIÓN CLIMÁTICA DIARIA es débil: se identifica por el día y la estación que la produce (relaciones identificadoras REGISTRADA EN y TOMADA EN).

Jerarquías

Jerarquías de agregación. Las cadenas ALCALDÍA ⊃ COLONIA ⊃ MANZANA y BIMESTRE ⊃ DÍA son jerarquías de agregación (niveles de un mismo eje), no de generalización. Se modelan con las relaciones identificadoras y con la relación COMPRENDE.

Jerarquías de especialización (ES-UN). No existen. El único candidato era el tipo de uso (doméstico, no doméstico, mixto). Se descartó porque los tres tipos tienen exactamente los mismos atributos y las mismas relaciones, de modo que subtipos sin atributos propios no aportan nada frente a un atributo discriminante (tipo_uso). Tampoco hay subtipos entre los niveles del índice de desarrollo, que son valores de un catálogo ordinal (ALTO, MEDIO, BAJO, POPULAR).

Hallazgos de los datos que respaldan las decisiones del modelo

- **El índice de desarrollo no es atributo de la colonia:** 1,200 de las 1,553 colonias tienen registros con más de un nivel. Tampoco es fijo para la manzana: 424 coordenadas cambian de nivel entre bimestres. Por eso se relaciona con la lectura.
- **consumo_total es derivado:** coincide con la suma de los tres usos salvo diferencias de redondeo (253 registros difieren en más de 0.02, con diferencia máxima de 0.37).
- **núm_cuentas es derivado:** el cociente consumo / promedio_por_cuenta es un entero en el 100 % de los registros mixtos y en el 99.99 % de los domésticos con promedio mayor que cero.

- **La coordenada no identifica a la manzana de forma única:** en 1,210 combinaciones de bimestre y coordenada hay más de un registro (3,789 registros en total), casi siempre con distinto índice.

Correspondencia entre el modelo y el esquema publicado

El esquema publicado está formado por ddl/0_schema.sql, etl/2_geo.sql (que añade coordenadas a dim_ubicacion y crea dim_ubicacion_adyacencia y la vista v_ubicacion_geom) y los scripts de ETL (1_copy.sql, 2_dim.sql, 3_fact.sql). La tabla relaciona cada entidad y relación del modelo con las tablas del esquema e indica qué información del dominio se pierde y cuál se agrega.

Elemento del modelo	Tabla(s) y columnas del esquema	Información del dominio que se pierde	Información que se agrega en el esquema
ALCALDÍA	dim_ubicacion.alcaldia (texto repetido en cada colonia; 16 valores distintos)	No existe como tabla: sin identificador propio, sin catálogo ni geometría.	—
COLONIA	dim_ubicacion (alcaldia, colonia, latitud, longitud); 1,553 filas	La dependencia de la alcaldía no está declarada: no hay restricción de unicidad sobre (alcaldia, colonia), solo el DISTINCT del ETL. Las 54 colonias con nombre repetido solo se distinguen por la alcaldía.	id_ubicacion (clave sustituta). latitud y longitud son el centroide, promedio de las coordenadas de sus registros (añadido por 2_geo.sql).
MANZANA	Ninguna	Se pierde por completo: sus 22,930 coordenadas y su identidad. Solo sobrevive como la granularidad implícita de cada fila de hecho.	—
ÍNDICE DE DESARROLLO	dim_indice_des (indice_des); 4 filas	El orden de los niveles (no hay columna de orden ni CHECK); el artículo lo declara solo en la capa RDF.	id_indice_des (clave sustituta).

Elemento del modelo	Tabla(s) y columnas del esquema	Información del dominio que se pierde	Información que se agrega en el esquema
BIMESTRE	dim_tiempo.anio y dim_tiempo.bimestre (repetidos en cada día)	No existe como tabla; los bimestres 4 a 6 están definidos en el CASE del ETL pero no tienen filas.	La fecha de referencia es la fila de dim_tiempo a la que apunta fact_consumo_agua.id_tiempo.
DÍA	dim_tiempo (fecha, anio, mes, dia, bimestre); 181 filas	—	id_tiempo (clave sustituta); los atributos derivados se materializan como columnas.
LECTURA DE CONSUMO	fact_consumo_agua; 70,886 filas	216 registros (0.30 %) no se cargan porque colonia y alcaldia son NA; el INNER JOIN los descarta sin dejar rastro.	id_fact (clave sustituta); consumo_total y consumo_prom se guardan como columnas.
CONSUMO POR USO	Seis columnas de fact_consumo_agua: consumo_total_dom, consumo_prom_dom, consumo_total_no_dom, consumo_prom_no_dom, consumo_total_mixto, consumo_prom_mixto	núm_cuentas no se guarda (solo se recupera dividiendo, y no cuando el consumo es 0). NULL (4,820 domésticos; 8,327 mixtos) y 0 conviven sin significado documentado.	El desglose por uso queda en columnas en lugar de filas (una columna por tipo y medida).

Elemento del modelo	Tabla(s) y columnas del esquema	Información del dominio que se pierde	Información que se agrega en el esquema
ESTACIÓN CLIMÁTICA	Ninguna	Se pierde por completo: sus coordenadas y altitud solo aparecen en el nombre del archivo open-meteo-19.44N99.11W2233m.csv. fact_clima no tiene dimensión de lugar, así que no admite más de una estación.	—
OBSERVACIÓN CLIMÁTICA DIARIA	fact_clima (temp_maxima, temp_minima, temp_promedio, humedad_promedio, lluvia_total); 181 filas	Se pasa de 4,344 mediciones horarias a una por día: se pierde la hora, la humedad máxima y mínima y la distribución de la lluvia.	id_fact_clima (clave sustituta); los agregados se calculan con MAX, MIN, AVG y SUM.
CERCANA A (relación)	dim_ubicacion_adyacencia (id_origen, id_vecino, distancia_km)	Es cercanía de centroides (≤ 1.5 km), no colindancia entre colonias; el umbral está fijo en el script.	Cada par se guarda en ambos sentidos; en la capa RDF se publica como agua:nearbyWithin1500m.
Sin entidad en el modelo	staging_consumo, staging_clima, v_ubicacion_geom	—	Tablas temporales del ETL, eliminadas al terminar la carga, y vista con la geometría en texto WKT para R2RML.

Resumen de lo que cambia al pasar del modelo al esquema

- **Se pierden:** la manzana, la estación climática, la resolución horaria del clima, el número de cuentas, el orden del índice de desarrollo y 216 registros sin territorio.
- **Se agregan:** claves sustitutas, el centroide por colonia, la tabla de proximidad entre colonias y las tablas de staging.

El modelo conceptual muestra que el esquema en estrella conserva la granularidad de los hechos, pero no los objetos del dominio que la sostienen.